

Desafio 2 — Ativação e Inicialização

$$f(x) = \text{ReLU}(x) = \max(0, x)$$

$$\sigma^2 = \frac{2}{\text{fan_in}} \quad (\text{He/Kaiming, viés} = 0)$$

Por quê (teoria)?

$\text{Var}(z) = \text{fan_in} \cdot \sigma^2 \cdot \text{Var}(x)$. Para o fator $(\text{fan_in} \cdot \sigma^2)$ ficar ≈ 1 com a ReLU (que corta metade do sinal), He propõe $\sigma^2 = 2/\text{fan_in}$.

A Constatação (crucial):

Nosso código espelha a Referência oficial com perfeição (acc = ref em todas as 9 tarefas) — validando que a implementação está matematicamente correta.

Porém, o raio-X do próprio harness mostra que, em $L=48$, a teoria diverge da prática: a variância da pré-ativação NÃO fica estável em ~ 1 — ela sobe de 2.1 (1ª camada) para 7.4 (última). Sem BatchNorm/residual, o pressuposto de independência da teoria de He se degrada com a profundidade, e o sinal se desvia do ponto ideal.

O Escore 38.9 reflete esse limite prático da inicialização pura em redes muito profundas.

Teoria vs. prática — MLP com $L = 48$ camadas (ReLU + He)

