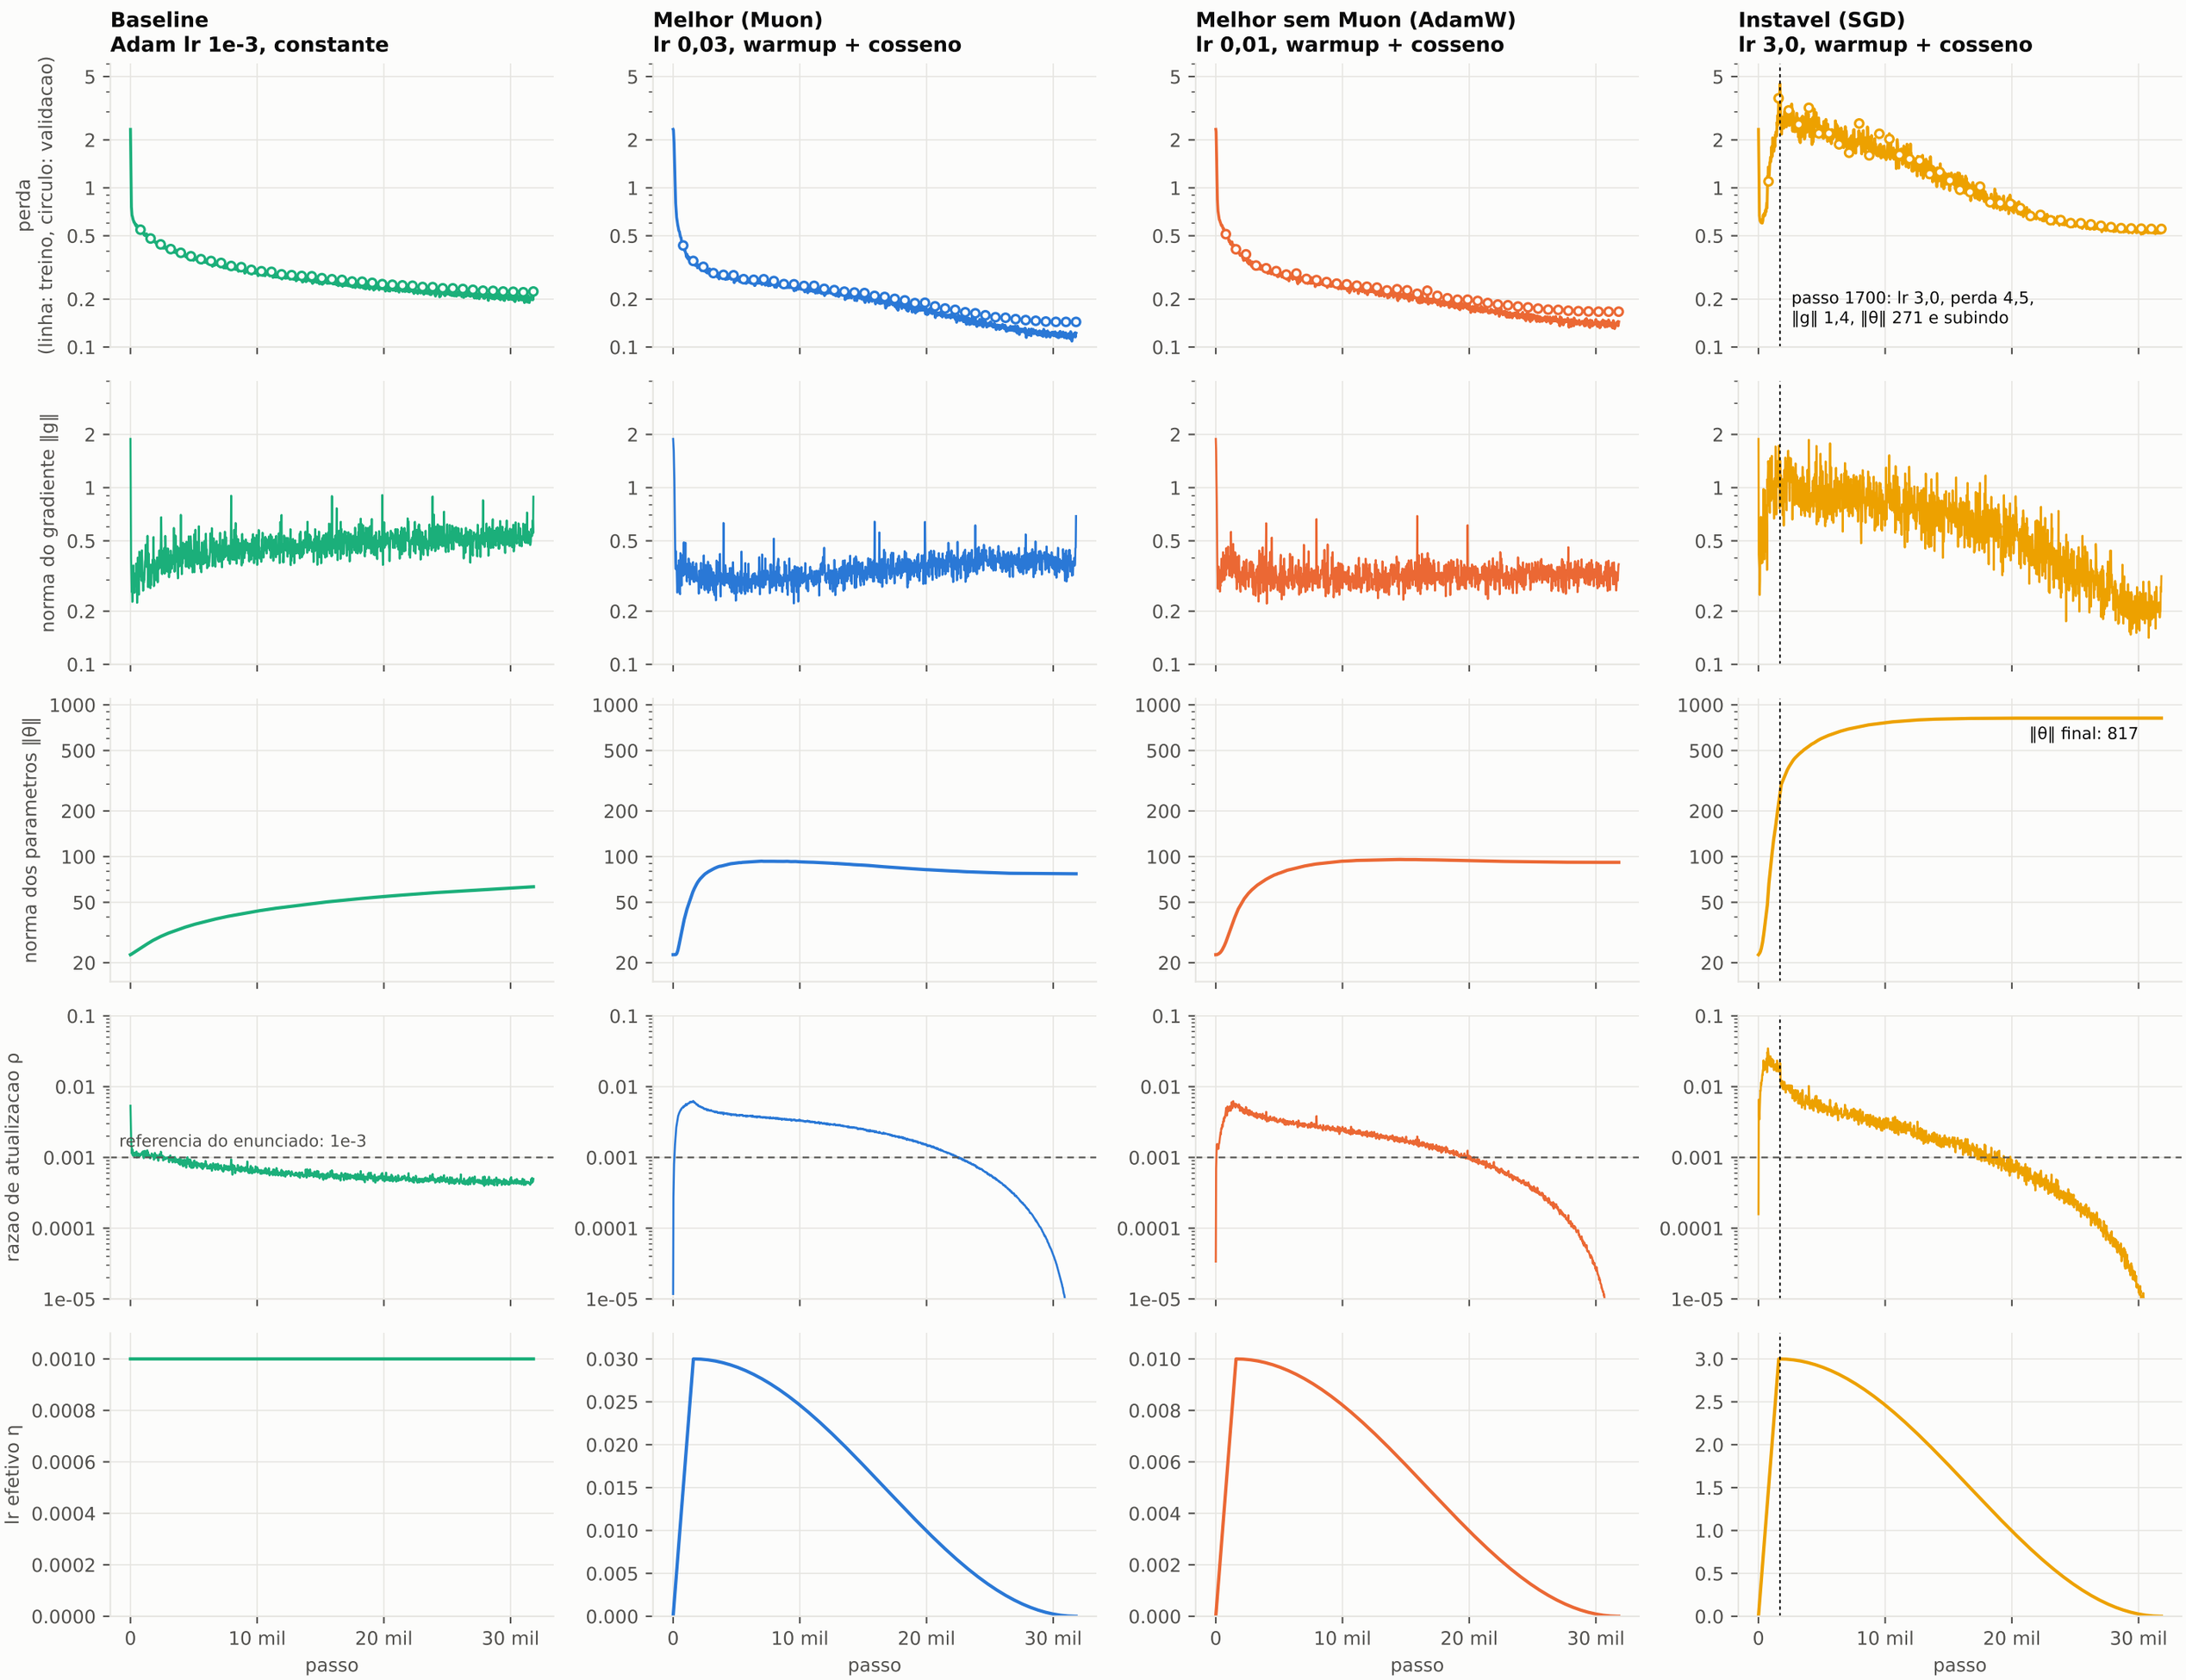
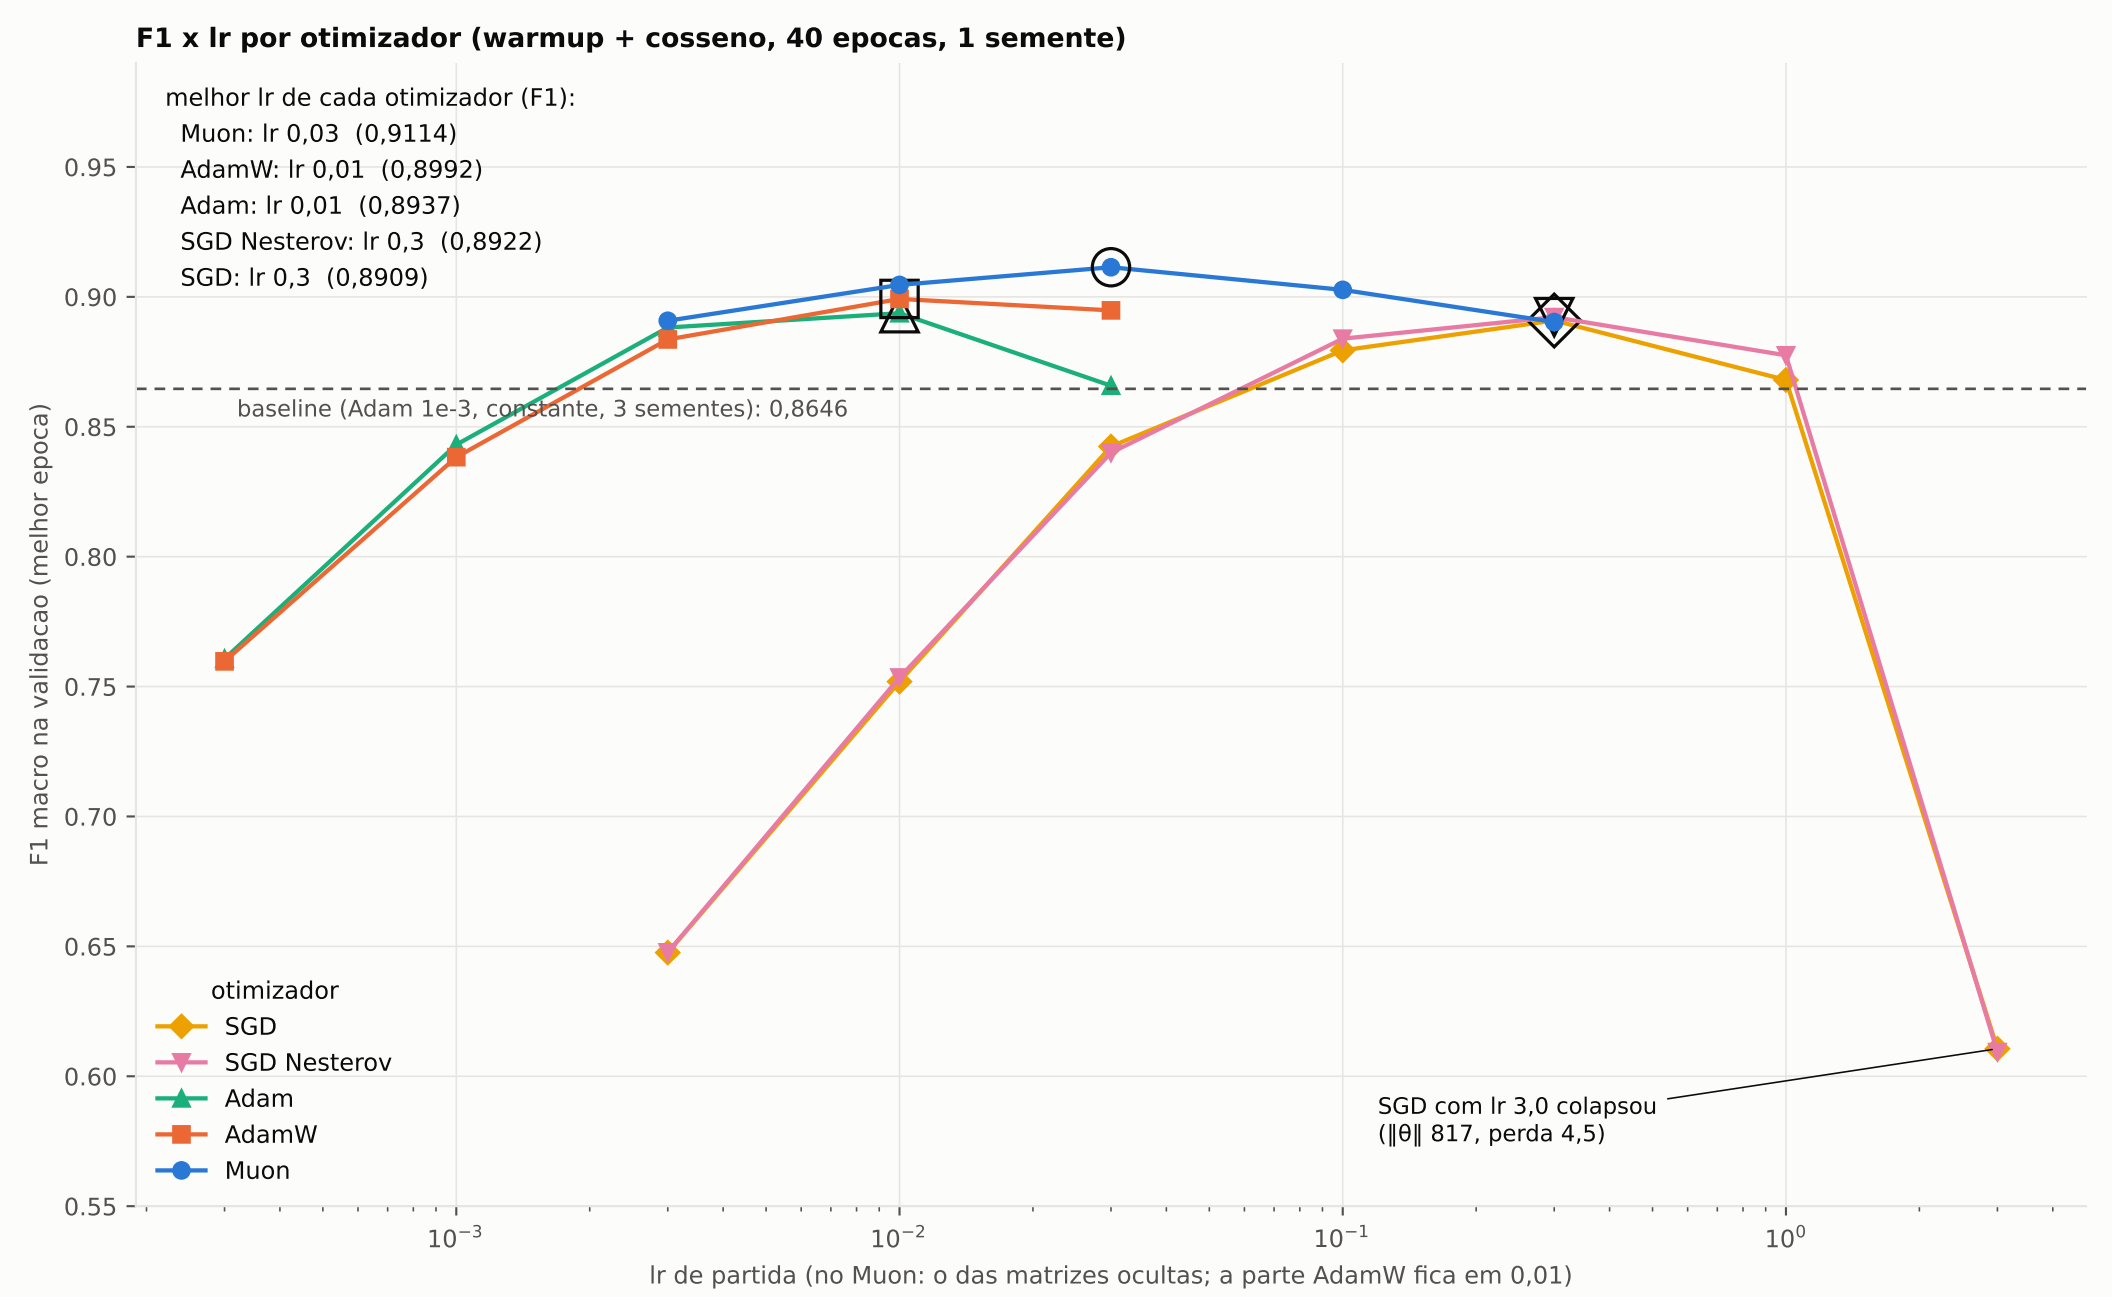
Desafio 3 - os sinais do treino alinhados no mesmo eixo de passos (40 epocas = 31.800 passos, semente 0)

Ler cada coluna de cima para baixo (mesmo passo em todos os graficos). Os eixos de perda, ‖g‖, ‖θ‖ e ρ sao logaritmicos e iguais entre as colunas.

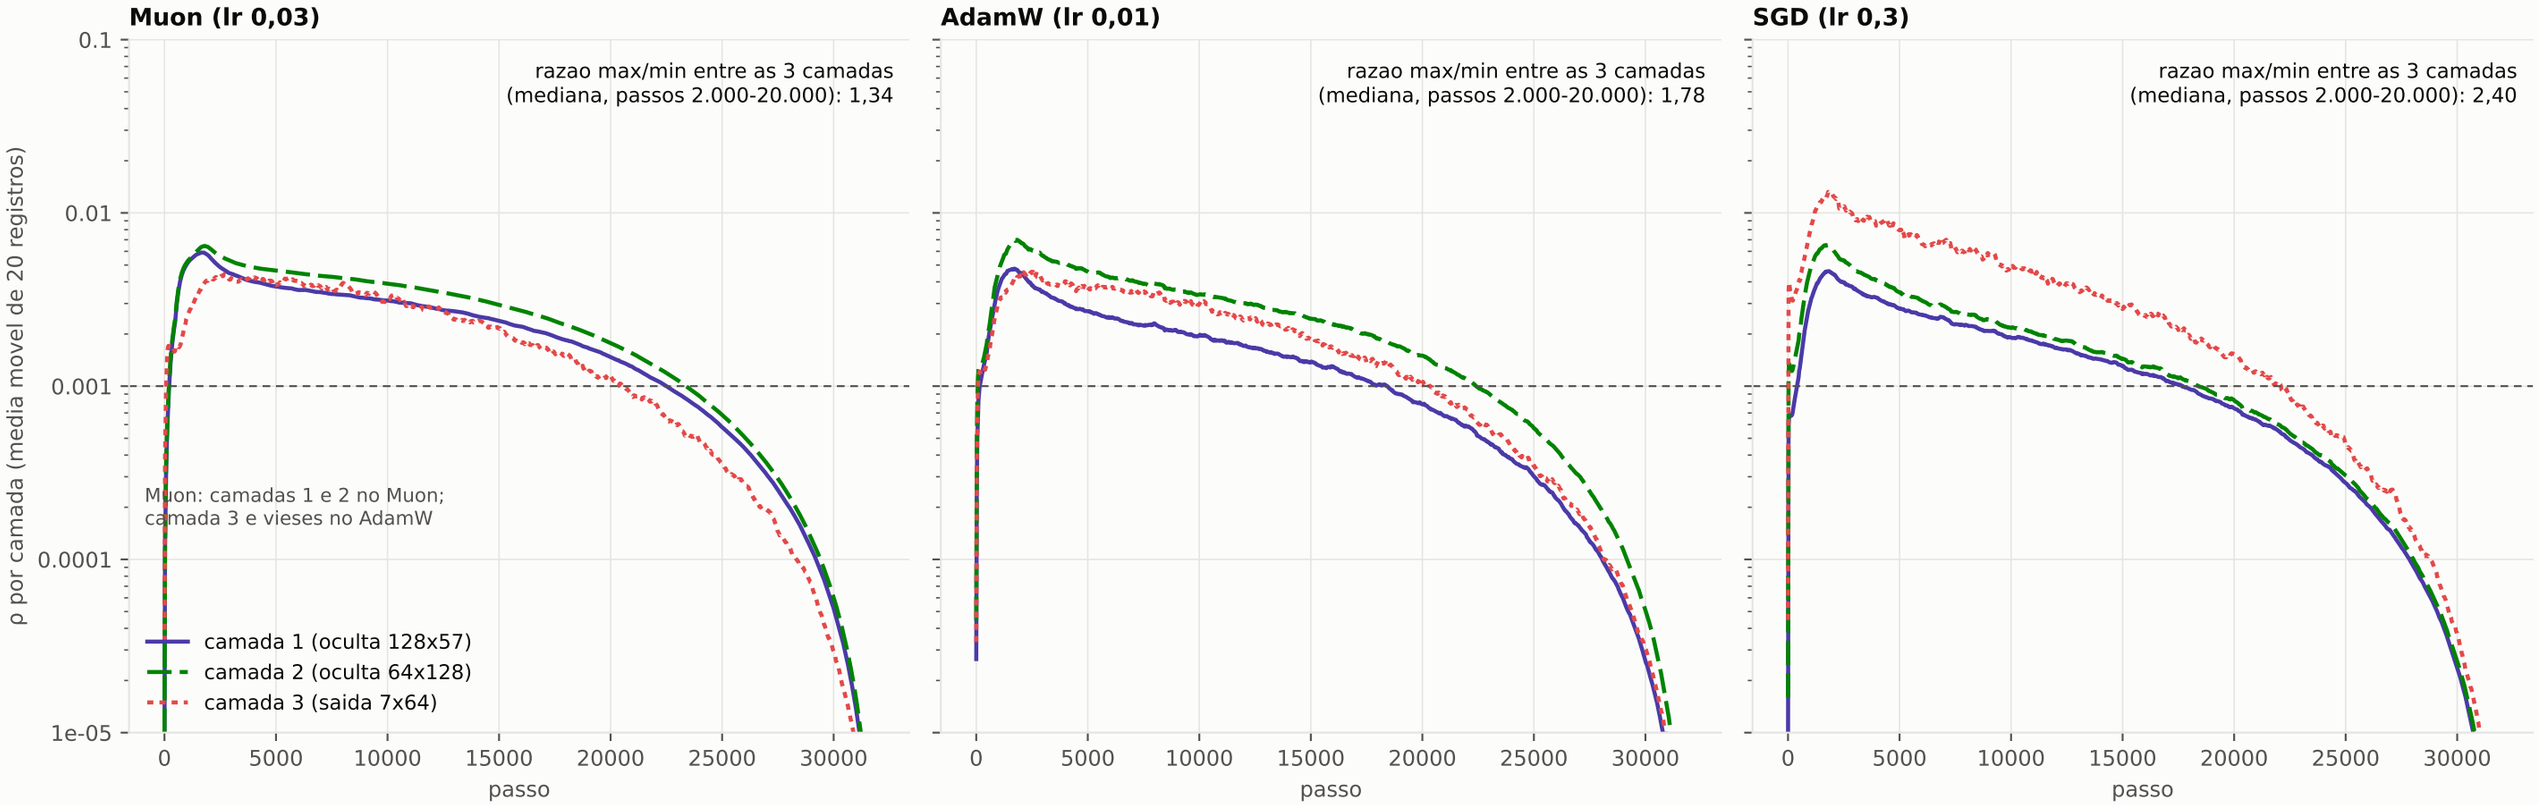




Circulo grande = melhor lr de cada otimizador (todos no interior da grade, depois de estender o SGD ate 3,0). 1 semente por ponto: diferencas < ~0,003 nao separam efeito de ruido.

Razao de atualizacao por camada: o Muon mexe nas camadas de forma mais parecida

1 semente por otimizador. Linha tracejada = referencia do enunciado (1e-3). A queda no fim vem da agenda: lr -> 0.



O que explica o ganho sobre a baseline

