Muon + queda do lr: +0,048 de F1 sobre a baseline, e o que os sinais mostram

Forest Covertype · MLP 57→128→64→7 (16 mil parâmetros) · protocolo do Desafio 3: lr ajustado por otimizador, 31.800 passos fixos, 3 sementes, teste usado uma única vez

Receita vencedora

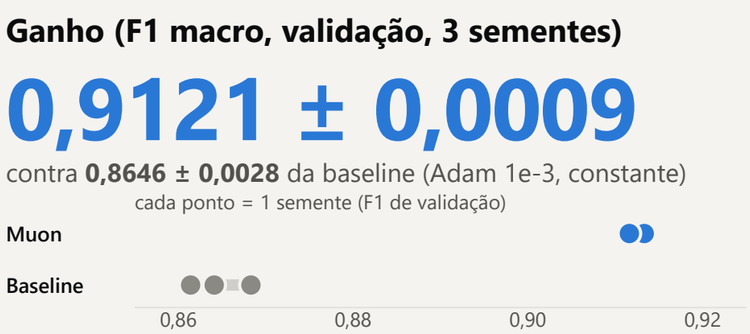
- **Muon**, lr 0,03, nas 2 matrizes ocultas (momento 0,95, Nesterov)
- **AdamW**, lr 0,01, nos vieses e na camada de saída
- agenda **warmup (5%) + cosseno até 0** · 40 épocas, 31.800 passos, lote 512

Comparados: SGD (± Nesterov), Adam, AdamW e Muon × 4 agendas. **52 execuções, nenhuma divergiu.**
Adotada no modelo final do projeto (modelo.py): teste 94,4%.

Ganho (F1 macro, validação, 3 sementes)

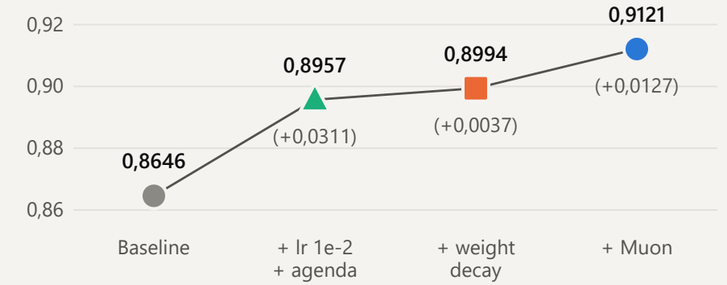
0,9121 ± 0,0009

contra **0,8646 ± 0,0028** da baseline (Adam 1e-3, constante)

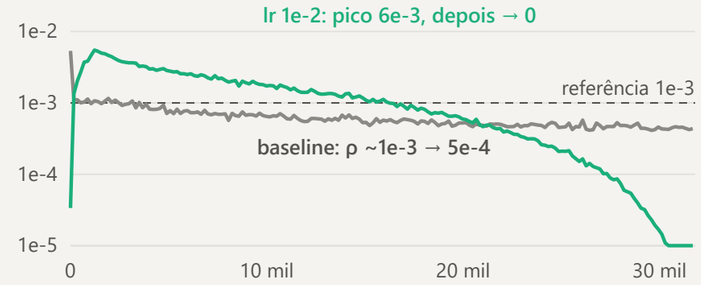


+0,0475 = 16× o desvio · Teste (1 uso): **0,9104** contra 0,8689

De onde vem o ganho



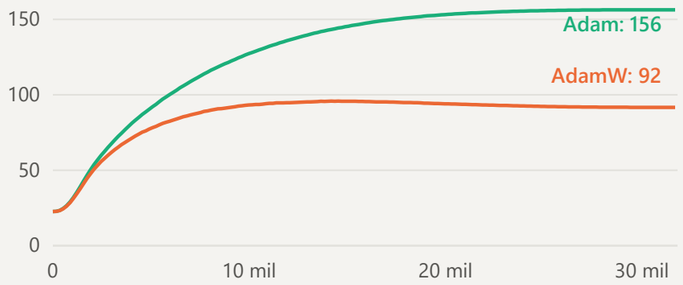
1 · lr maior + queda a zero +0,031 · ⅔ do ganho



A baseline mexe pouco: ρ cai de 1e-3 a **5e-4** e a perda de treino fica em **0,201** (subajustada). Com lr 0,01 o ρ chega a **6e-3** e a agenda o leva a ~0: perda de treino **0,132**.

Lido em: ρ (razão de atualização) e perda de treino.

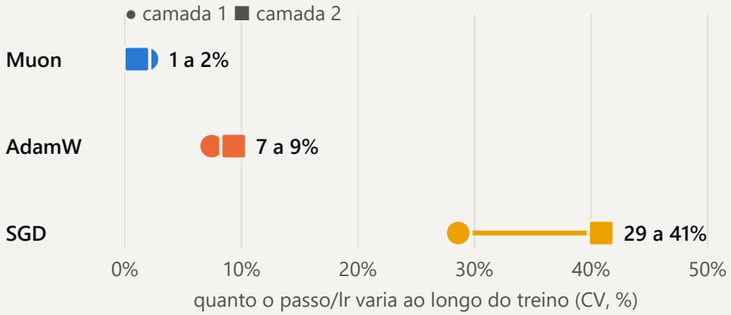
2 · Weight decay +0,004



Sem weight decay a norma dos pesos cresce até **154–156** (3 sementes); com AdamW estabiliza em **91–92**. Ele controla a norma, mas o F1 quase não muda: o gargalo **não era sobreajuste**.

Lido em: ||θ|| (norma dos parâmetros).

3 · Muon +0,013



O passo do Muon é ≈ **lr × √(menor dimensão)**, quase constante: medido **9,8 e 7,3** contra **11,3 e 8,0** previstos. O do SGD depende do gradiente.

Lido em: ||Δθ|| / lr por camada (tamanho do passo).

O que NÃO afirmamos

- Só **um quarto** do ganho é do Muon. Dois terços vêm de lr + agenda, que o Adam sozinho já captura (0,8957).
- Com lr **constante** o Muon perde do AdamW (0,847 contra 0,853): a vantagem exige a queda do lr. Custa ~9,5× mais por época.
- Com **200 épocas** o ganho cai para +0,019 (1 semente): parte do ganho é convergir mais rápido, sob orçamento curto.