Muon + queda do lr: +0,048 de F1 sobre a baseline, e o que os sinais mostram

Forest Covertype · MLP 57→128→64→7 (16 mil parâmetros) · Desafio 3: o melhor treino para o nosso problema

Receita vencedora

- **Muon**, lr 0,03, nas 2 matrizes ocultas (momento 0,95, Nesterov)
- **AdamW**, lr 0,01, nos vieses e na camada de saída
- agenda **warmup (5%) + cosseno até 0**
- 40 épocas = 31.800 passos, lote 512, igual para todos

Comparados: SGD (± Nesterov), Adam, AdamW e Muon × 4 agendas, com o lr ajustado em cada um. **54 execuções, nenhuma divergiu.**

Adotada no modelo final do projeto (modelo.py): teste 94,4%.

Para explicar

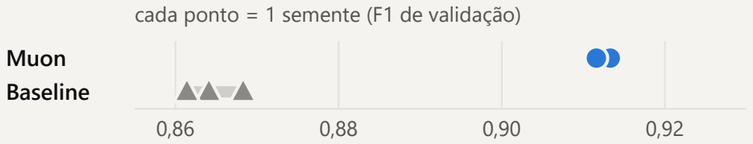
- **F1 macro**: média do F1 das 7 classes; as classes raras pesam igual às grandes.
- **Semente**: sorteia a inicialização e a ordem dos lotes. O desvio mostra quanto o resultado muda só por isso.
- **ρ** = ||Δθ||/||θ||: tamanho relativo do passo (referência do enunciado: 1e-3).
- **Muon**: o passo das matrizes é ortogonalizado, então todas as direções andam o mesmo tanto.
- **Warmup + cosseno**: o lr sobe em 5% do treino e desce suave até 0.

Ganho (F1 macro, validação)

40 ÉPOCAS · 3 SEMENTES (PROTOCOLO)

0,9121 ± 0,0009

contra **0,8646 ± 0,0028** da baseline (Adam 1e-3, constante)

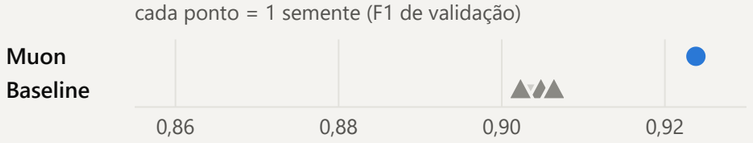


+0,0475 = 16× o desvio entre sementes

200 ÉPOCAS · 1 SEMENTE (COMPLEMENTO)

0,9238

contra **0,9045** da baseline

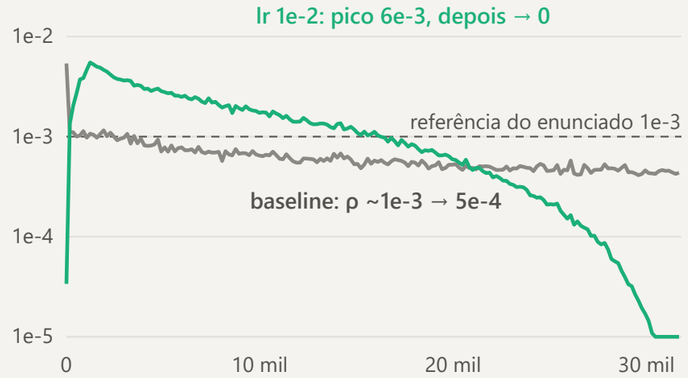


+0,0193 (1 semente: sem desvio)

Teste (usado uma única vez): F1 **0,9104** contra 0,8689 · acurácia 94,4% contra 91,3%

Diagnóstico lido nos sinais

lr maior + queda a zero explica ⅔ do ganho (+0,031)



A baseline mexe pouco: ρ cai de 1e-3 a **5e-4** e a perda de treino fica em **0,201** (subajustada). Com lr 0,01 o ρ chega a **6e-3** e a agenda o leva a ~0: perda de treino **0,132**.

Lido em: ρ (razão de atualização) e perda de treino. Detalhe na página 6.

Como comparamos: o protocolo do enunciado, em 4 etapas

Mesmo orçamento para todas as comparações: 40 épocas × 795 passos = 31.800 passos, lote 512 · validação decide, teste só no final · 54 execuções reportadas

ETAPA 1

Baseline

A receita atual do grupo: Adam lr 1e-3, agenda constante, 3 sementes.

3 execuções
F1 0,8646 ± 0,0028

ETAPA 2

Varredura de lr

Cada otimizador (SGD, Nesterov, Adam, AdamW, Muon) com 5 a 7 valores de lr em escala log, warmup + cosseno, 1 semente. O SGD foi estendido até 3,0 porque o melhor caiu na borda.

29 execuções
Melhor: Muon lr 0,03 (0,9114)

ETAPA 3

Agendas

As 4 agendas (constante, cosseno, warmup + cosseno, WSD) para o AdamW (lr 0,01) e o Muon (lr 0,03), cada um com o seu melhor lr, 1 semente.

6 execuções novas
Vence warmup + cosseno nos dois

ETAPA 4

Confirmação

As melhores combinações com 3 sementes, incluindo AdamW e Adam com o mesmo lr e agenda (para separar o efeito de cada degrau). Complemento declarado: vencedora e baseline também com 200 épocas.

18 execuções (14 de 40 épocas, 4 de 200)
Vencedora: 0,9121 ± 0,0009

Regras do enunciado e como cumprimos

✓ **lr ajustado por otimizador**: varredura própria de cada um (e do Muon sobre o melhor lr do AdamW).

✓ **Mesmo orçamento** (passos e lote) em todas as comparações.

✓ **Seleção na validação**; o teste foi usado **uma única vez**, no fim.

✓ **Tudo reportado**, inclusive o que falhou: nenhuma execução divergiu; o SGD com lr 3,0 colapsou (F1 0,61).

✓ **Só há vencedor se a diferença supera a variação entre sementes**: +0,048 contra desvios de 0,0009 e 0,0028.

✓ **Muon incluído** (`torch.optim.Muon`, só nas matrizes 2-D ocultas; vieses e saída no AdamW).

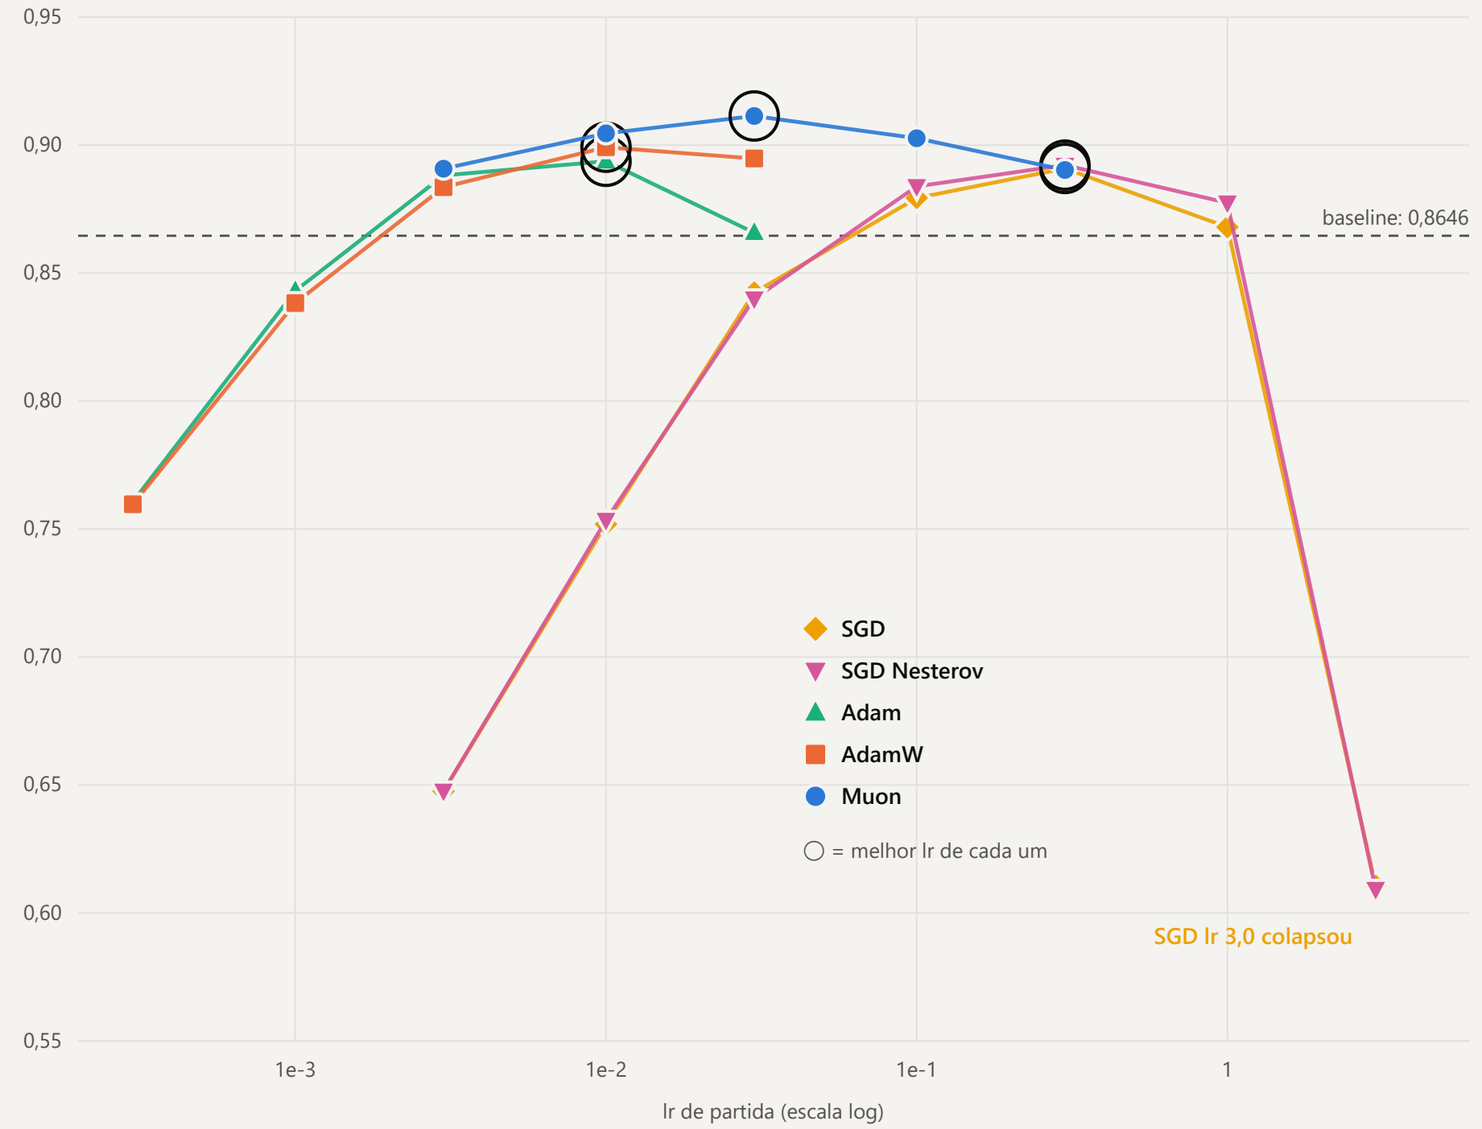
✓ **Reprodutível**: cada linha do `experimentos.csv` traz o comando exato.

Escolhas nossas, declaradas

- **40 épocas em todas as etapas**, inclusive baseline e confirmação, por limite de CPU: o Muon custa ~8,8× mais por época. O enunciado só autoriza reduzir nas etapas 2–3, então declaramos e fizemos o complemento de 200 épocas com 1 semente.
- **WSD** como 4ª agenda (a "à escolha"): warmup 5%, estável até 80% e queda linear até 0.
- **Registro a cada 25 passos** (o enunciado permite de 10 a 50), global e por camada.
- **Só o lr foi ajustado**: momento (SGD 0,9; Muon 0,95 com Nesterov) e weight decay (AdamW e Muon 0,01; Adam sem) ficaram fixos.
- **Complemento declarado**: sementes 1 e 2 do AdamW e do Adam, porque o top-3 foi todo Muon e "Muon > AdamW" ficaria sustentado por 1 semente.

Etapa 2: o melhor lr de cada otimizador, todos no interior da grade

F1 macro na validação × lr de partida · warmup + cosseno · 40 épocas · 1 semente por ponto · no Muon, o lr das matrizes (a parte AdamW fica em 0,01)



Melhor lr de cada otimizador

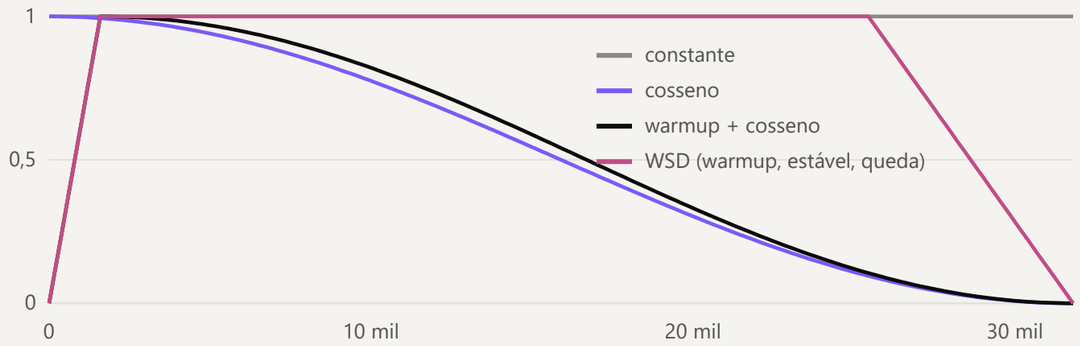
otimizador	melhor lr	F1
Muon	0,03	0,9114
AdamW	0,01	0,8992
Adam	0,01	0,8937
SGD Nesterov	0,3	0,8922
SGD	0,3	0,8909

- O Muon (**0,9114**) está acima de todos, e todos os melhores lr ficam **no interior** da grade.
- Adam e AdamW pedem lr ~10× menor que o SGD, e o Muon (matrizes) fica no meio.
- O SGD com lr 3,0 **colapsou** (F1 0,61): é a execução instável (página 7).
- 1 semente por ponto: diferenças menores que ~0,003 não separam efeito de ruído. A confirmação com 3 sementes está na página 4.

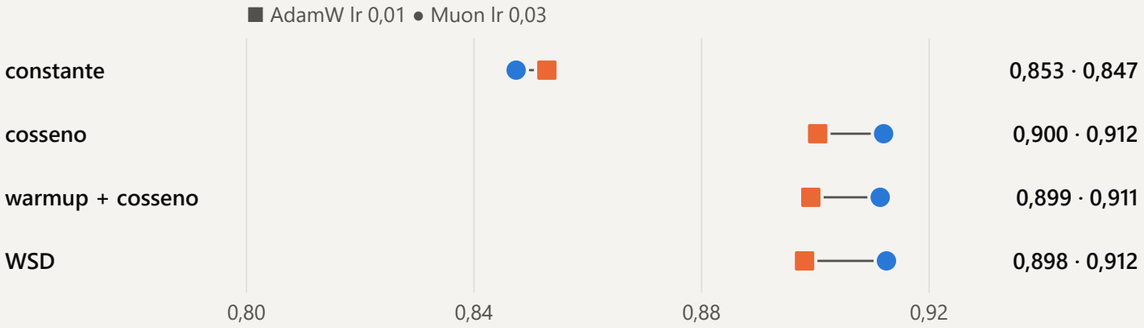
Etapas 3 e 4: as 4 agendas e a confirmação com 3 sementes

Etapa 3 com 1 semente (AdamW lr 0,01 e Muon lr 0,03) · etapa 4 com 3 sementes nas melhores combinações, 40 épocas

As 4 agendas (fator sobre o lr de partida)

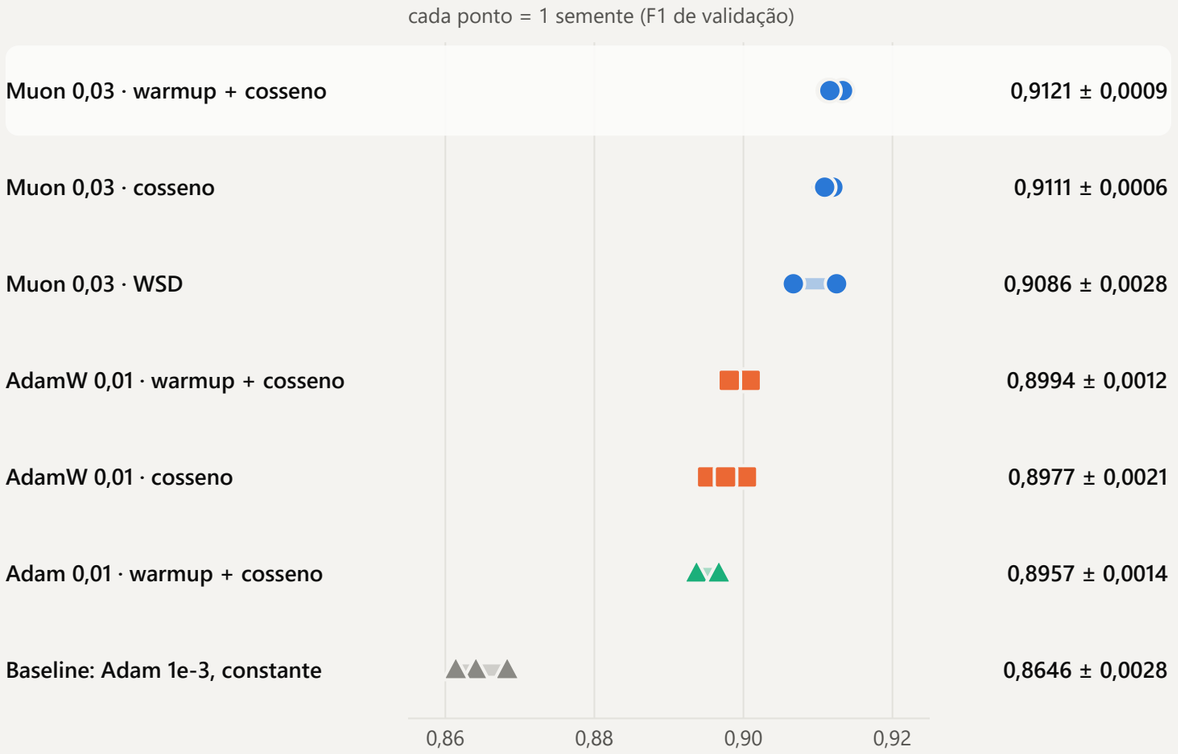


F1 por agenda · 1 semente



Com lr **constante** o Muon perde do AdamW (**0,847** contra **0,853**): a vantagem do Muon exige a queda do lr. O WSD ficou abaixo do warmup + cosseno nos dois.

Confirmação · F1 por semente (média ± desvio)



- **Vencedora:** Muon lr 0,03 com warmup + cosseno, **0,9121 ± 0,0009**, contra 0,8646 ± 0,0028 da baseline.
- Cosseno puro empata com warmup + cosseno (0,9111 ± 0,0006): a diferença de 0,0010 é menor que o desvio, então o **warmup não fez diferença** aqui.
- O WSD fica 0,0035 abaixo e é mais instável entre sementes (desvio 0,0028).
- AdamW (0,8994) e Adam (0,8957) com o mesmo lr e agenda: o weight decay soma +0,0037.

De onde vem o ganho de +0,0475: três degraus

F1 macro de validação, média de 3 sementes ± desvio · cada degrau muda uma coisa só



1 · lr maior + queda a zero

+0,031 · ⅔ do ganho

Trocar o lr de 1e-3 para 1e-2 e deixá-lo cair a zero com warmup + cosseno, ainda com o Adam: F1 de 0,8646 para **0,8957**. A baseline andava pouco e ficava subajustada.

Diagnóstico na página 6, lido em ρ e perda de treino

2 · Weight decay

+0,004

Trocar Adam por AdamW (weight decay 0,01), com o mesmo lr e agenda: 0,8957 para **0,8994**. Controla a norma dos pesos, mas o F1 quase não muda.

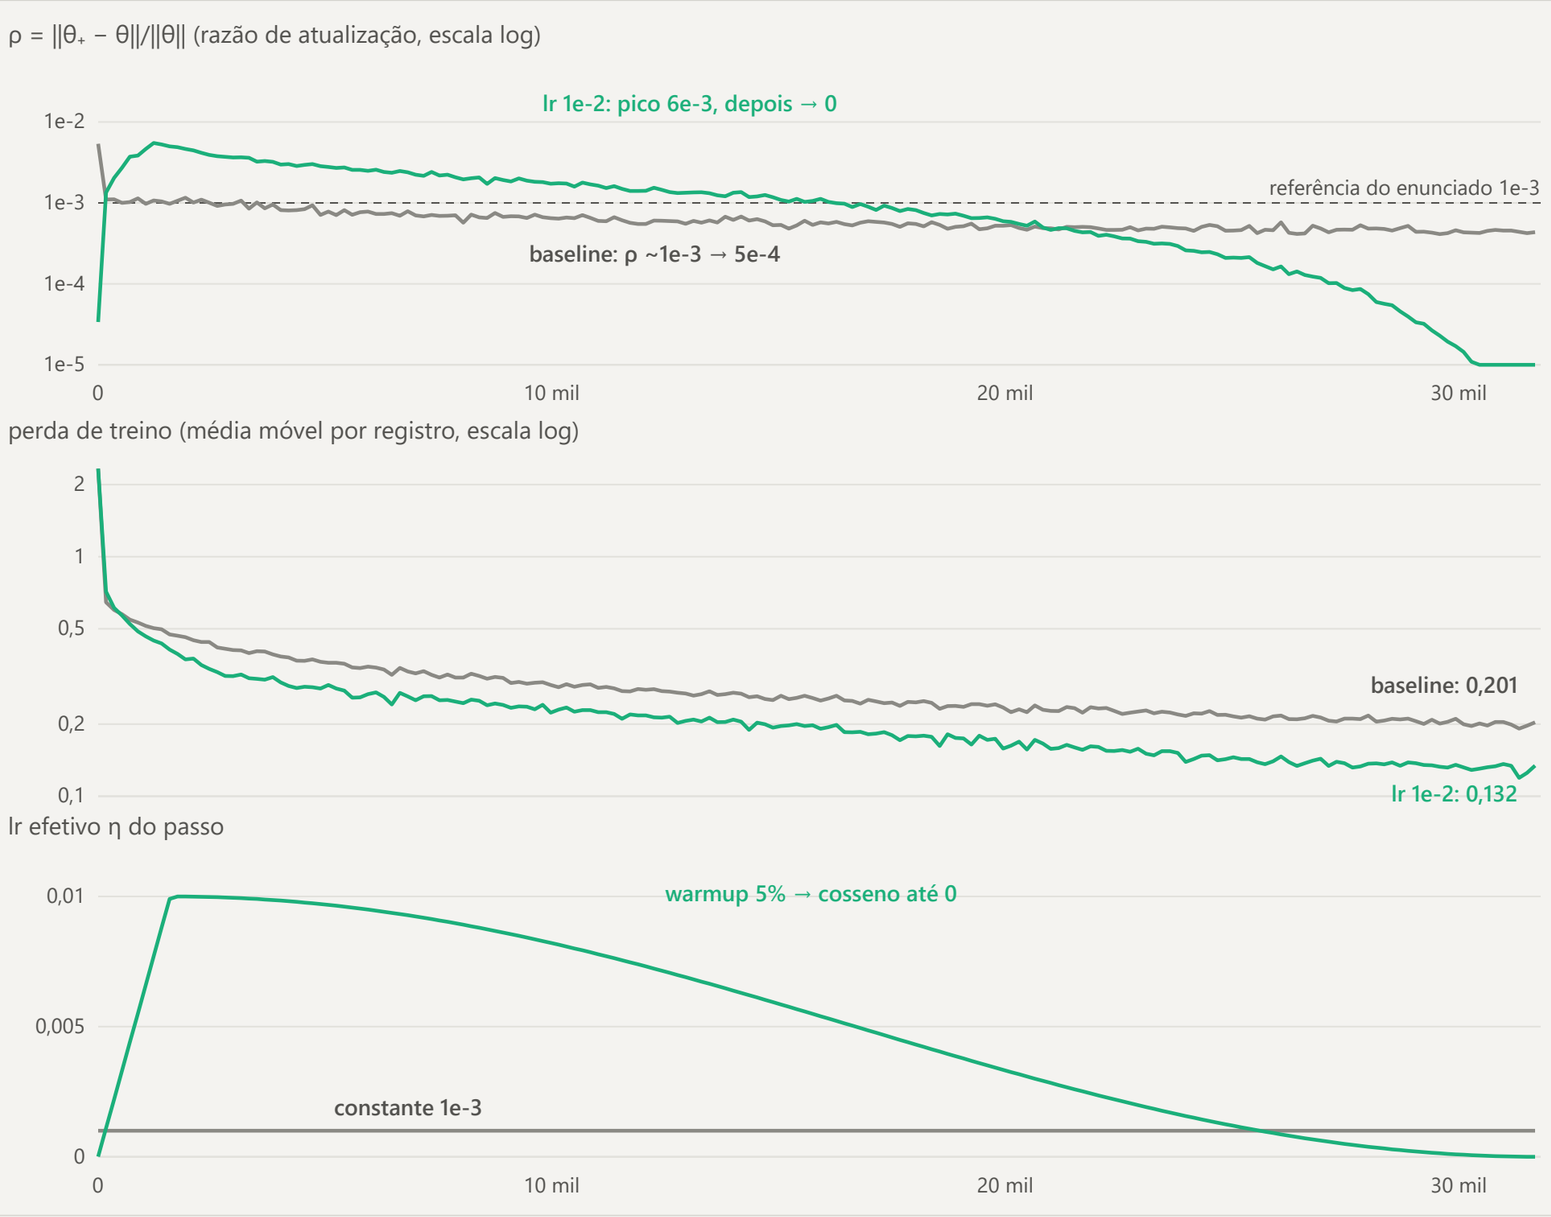
3 · Muon

+0,013 · ¼ do ganho

Usar o Muon nas 2 matrizes ocultas (AdamW no resto): 0,8994 para **0,9121**. Só um quarto do ganho, e ele exige a agenda que decai.

Diagnóstico 1 · lr maior + queda a zero (+0,031, ⅔ do ganho)

Baseline (Adam 1e-3, constante) contra Adam lr 1e-2 com warmup + cosseno · mesmo eixo de passos: ler cada coluna vertical nos três gráficos



O que os sinais mostram

- **Baseline:** ρ começa perto de 1e-3 e cai para **5e-4**. A perda de treino termina em **0,201**: a rede anda pouco, está subajustada.
- **Adam lr 1e-2:** ρ sobe até **6e-3** (6× a referência) e a agenda o leva a ~0. A perda de treino termina em **0,132**.
- **Duas forças:** lr grande no começo para andar mais; lr perto de zero no fim, porque o ruído do mini-lote faz o iterado oscilar em torno do vale e a queda o "assenta".
- O warmup de 5% mostra o ρ subindo de ~0 no início (na coluna do passo 0 a 1.600), sem pico de instabilidade.

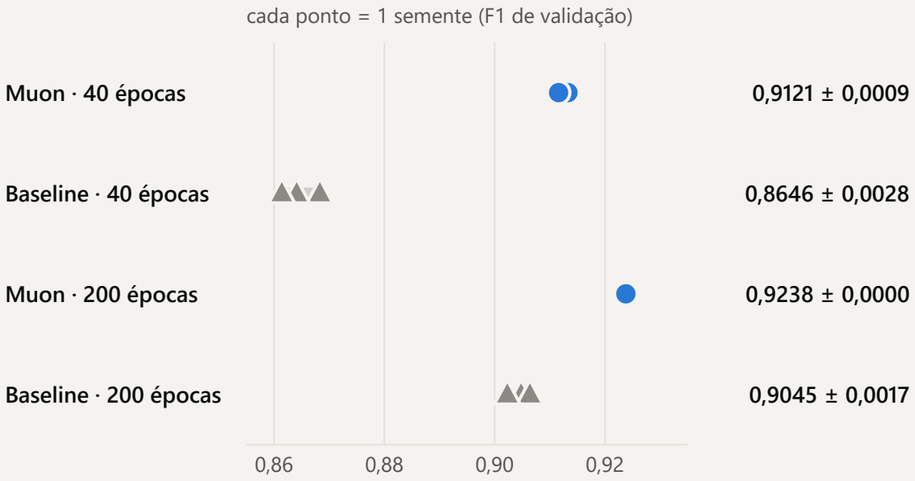
Como ler (tabela do enunciado)

ρ ≈ 1e-3 é a referência. Passo pequeno demais deixa o treino subajustado: o remédio é η maior. A queda brusca no fim do cosseno é esperada: o decaimento final "assenta" no vale.

Limitações e execução instável

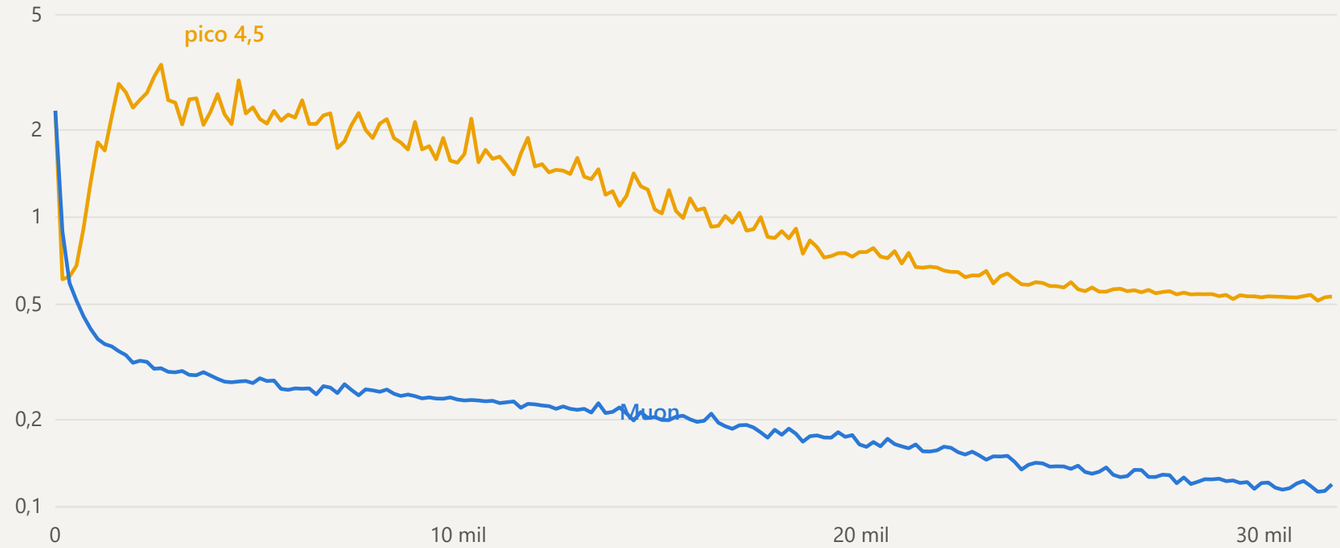
O que o resultado não prova, e o que a execução que falhou mostra nos sinais

Mais treino: o ganho encolhe



Com 40 épocas o ganho é **+0,0475** (16× o desvio). Com 200 épocas (1 semente) cai para **+0,0193**. A rede ainda não saturou em 40 épocas: parte do ganho do Muon é **velocidade**. Com 1 semente não dá para afirmar que supera o desvio.

Execução instável: SGD, lr 3,0



Com lr 3,0 a perda **sobe a 4,5** no passo 1.700 e ||θ|| chega a 271 e continua subindo (817 no fim): **passo grande demais**. A agenda recupera em parte (F1 0,61), mas a rede não volta. Ao lado, a perda do Muon desce sem picos.

Como ler: perda subindo e ||θ|| crescendo sem parar é o sintoma de passo grande demais (o remédio é um lr menor). É o contrário do que o gráfico mostra para a receita vencedora.