1 · Ponto de partida: por que o Covertype e o que precisamos treinar

Trocamos de dataset para ter um problema com espaço para aplicar a disciplina; o Desafio 3 pergunta como treinar bem a rede que esse problema comporta

Por que mudamos de dataset

	Dataset inicial	Forest Covertype (atual)
Objetivo	Recomendar a cultura a plantar, a partir das condições de solo e clima	**Prever a cobertura vegetal** de uma célula de terreno, a partir de relevo, solo e distâncias
Linhas	2.200	**581.012**
Classes	22 culturas	**7 coberturas vegetais**
Acerto no teste	98,6% (chute: 4,5%)	91,3% na baseline (chute: 48,8%)
Situação	Saturado: já acertava quase tudo	Há margem para melhorar

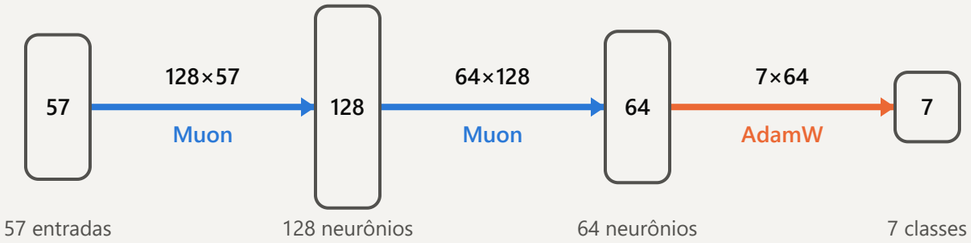
O problema do dataset inicial: era pequeno e fácil demais. Com 98,6% de acerto, qualquer mudança no treino seria invisível, e uma rede maior não cabia na regra de ~20 exemplos de treino por parâmetro.

O que o Covertype dá: volume para uma rede de tamanho razoável dentro dessa regra, classes desbalanceadas como no mundo real e margem para evoluir. Queríamos dar mais **espaço para aplicar os conceitos da disciplina** (inicialização, ativação, otimizadores).

O problema e a rede que vamos treinar

Cada exemplo é uma célula de terreno de 30×30 m (Colorado), descrita por relevo, distâncias e solo. **Objetivo da rede:** dizer qual das **7 coberturas vegetais** (tipos de floresta) domina ali. Mesma ideia de antes (condições do terreno → categoria), num problema maior.

cada seta = uma matriz de pesos (e o otimizador que a atualiza)



- **16.135 parâmetros** (57×128+128, 128×64+64 e 64×7+7): cerca de **25 exemplos de treino por parâmetro** (406.708 de treino). As 54 variáveis originais viram 57 entradas no pré-processamento.
- Classes desbalanceadas: chutar sempre a mais comum acerta **48,8%**, por isso medimos o **F1 macro**.

Onde o Desafio 3 entra

A rede, a ativação (tanh) e a inicialização (calibrada, do Desafio 2) já estão definidas. O Desafio 3 muda só **como a rede é treinada**: o otimizador e a agenda do lr.

O enunciado pede como **baseline** a "receita atual do grupo": o treino padrão do nosso projeto, **Adam, lr 1e-3, agenda constante**, sem ajuste nenhum. A pergunta é se existe uma receita melhor e, se existir, **por que** ela é melhor.

Receita = a combinação de otimizador + lr + agenda. **Baseline** = a receita de referência, contra a qual medimos todo ganho.

Termos que aparecem nos slides

- **Otimizador**: a regra que usa o gradiente para atualizar os pesos (SGD, Adam, AdamW, Muon).
- **lr** (taxa de aprendizado): o tamanho do passo. **Agenda**: como o lr muda ao longo do treino.
- **Passo / época**: 1 passo = 1 lote de 512 exemplos; 1 época = 795 passos (uma volta nos dados).
- **Validação / teste**: a validação decide as escolhas; o teste é medido uma única vez, no fim.
- **Semente**: sorteia a inicialização e a ordem dos lotes. O desvio entre sementes mostra quanto o resultado muda só por sorte.
- **F1**: nota de 0 a 1 do acerto numa classe (equilibra falsos alarmes e casos perdidos). **F1 macro**: média das 7 classes; as raras pesam igual às grandes.
- **ρ** = $\|\Delta\theta\|/\|\theta\|$: tamanho relativo do passo (referência do enunciado: 1e-3). **$\|\theta\|$**: norma dos pesos.
- **Muon**: o passo das matrizes ocultas é ortogonalizado, então todas as direções andam o mesmo tanto.
- **Warmup + cosseno**: o lr sobe em 5% do treino e depois desce suave até 0.

2 · O que o desafio pedia e como respondemos

O enunciado define o protocolo em 4 etapas; o que ficou aberto nós decidimos e declaramos · 56 execuções reportadas, nenhuma divergiu

Pergunta do enunciado: qual combinação de otimizador e agenda de lr treina melhor a nossa rede, e **por quê**, lido nos sinais do treino (perda, gradiente, ||θ||, ρ e lr efetivo)? **Otimizadores:** SGD (com e sem Nesterov), Adam, AdamW e Muon (obrigatório). **Agendas:** constante, cosseno, warmup + cosseno e uma à escolha (**WSD**).

ETAPA 1

Baseline com 3 sementes

A "receita atual do grupo", como o enunciado pede: o treino padrão do projeto (Adam, lr 1e-3, agenda constante), com 3 sementes.

3 execuções · F1 0,8646 ± 0,0028

ETAPA 2

Varredura de lr

Cada otimizador com 5 a 7 valores de lr em escala log (warmup + cosseno, 1 semente). O melhor do SGD caiu na borda, então estendemos a grade até 3,0.

29 execuções · melhor: Muon lr 0,03 (0,9114)

ETAPA 3

Agendas

As 4 agendas (constante, cosseno, warmup + cosseno, WSD) no AdamW (lr 0,01) e no Muon (lr 0,03), cada um no seu melhor lr, 1 semente.

6 execuções novas · vence warmup + cosseno nos dois

ETAPA 4

Confirmação com 3 sementes

As melhores combinações com 3 sementes; incluímos AdamW e Adam no mesmo lr e agenda para separar o efeito de cada ingrediente. Mais o complemento de 200 épocas.

20 execuções (14 de 40 épocas, 6 de 200) · vencedora: 0,9121 ± 0,0009

Regras do enunciado e como cumprimos

✓ **lr ajustado por otimizador**: varredura própria de cada um (o Muon, sobre o melhor lr do AdamW).

✓ **Mesmo orçamento** (passos e lote) em todas as comparações.

✓ **Escolha na validação**; o teste foi usado **uma única vez**, no fim.

✓ **Tudo reportado**, inclusive o que falhou: nenhuma execução divergiu; o SGD com lr 3,0 colapsou (F1 0,61).

✓ **Só há vencedor se a diferença supera a variação entre sementes**: +0,048 contra desvios de 0,0009 e 0,0028.

✓ **Muon incluído** (`torch.optim.Muon`, só nas matrizes 2-D ocultas; vieses e saída no AdamW).

✓ **Reprodutível**: cada linha do `experimentos.csv` traz o comando exato.

O que ficou aberto: nossas escolhas e o porquê

- **Orçamento de 40 épocas (31.800 passos, lote 512) em tudo:** o protocolo exige dezenas de execuções e o Muon custa ~9,2× mais por época na CPU. Usamos o mesmo orçamento em baseline, varredura e confirmação para comparar igual com igual.
- **WSD como 4ª agenda:** está nas leituras do enunciado e contrasta com as outras: tem o platô do lr constante e a queda final do cosseno.
- **Registro a cada 25 passos:** o enunciado permite de 10 a 50; dá ~1.270 pontos por execução, curvas suaves sem inflar os logs.
- **Só o lr foi ajustado:** mexer em mais coisas impediria saber o que causou o ganho. Momento e weight decay ficaram nos valores padrão.
- **Sementes extras de AdamW e Adam:** o top-3 da etapa 3 era todo Muon; sem elas, "Muon > AdamW" ficaria apoiado em 1 semente.
- **Complemento de 200 épocas:** em 40 épocas a rede ainda não saturou. O enunciado só permite reduzir o orçamento nas etapas 2 e 3, então declaramos e medimos a diferença.

3 · O que encontramos: Muon + queda do lr dá +0,048 de F1 sobre a baseline

Do melhor lr de cada otimizador, passando pelas agendas, até a confirmação com 3 sementes

Receita vencedora

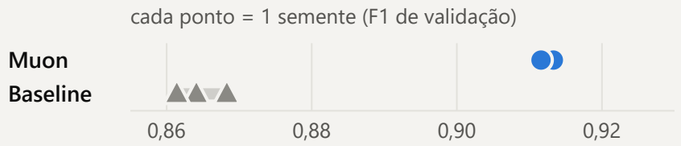
- **Muon**, lr 0,03, nas 2 matrizes ocultas (momento 0,95, Nesterov)
- **AdamW**, lr 0,01, nos vieses e na camada de saída
- agenda **warmup (5%) + cosseno até 0**
- 40 épocas = 31.800 passos, lote 512, igual para todos

Ganho (F1 macro, validação)

40 ÉPOCAS · 3 SEMENTES

0,9121 ± 0,0009

contra **0,8646 ± 0,0028** da baseline (Adam 1e-3, constante)



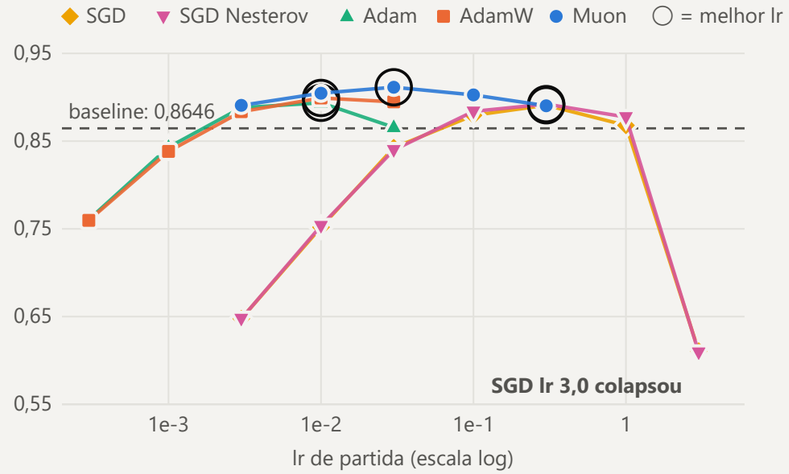
+0,0475 = 16× o desvio entre sementes

Teste (usado uma única vez): F1 **0,9104** contra 0,8689 · acurácia 94,4% contra 91,3%

É a receita adotada no modelo final do projeto (`modelo.py`).

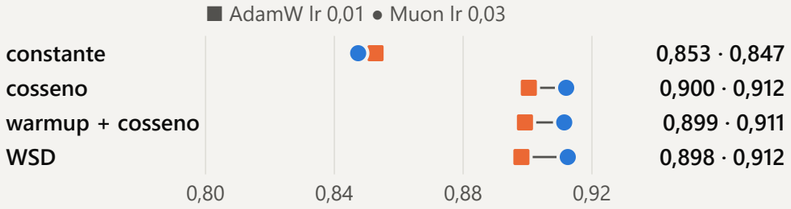
As duas nuvens de pontos não se tocam: a diferença não é sorte de semente.

Etapa 2 · o melhor lr de cada otimizador



- **Melhor lr:** Muon 0,03 (0,911) · AdamW 0,01 (0,899) · Adam 0,01 (0,894) · SGD Nesterov 0,3 (0,892) · SGD 0,3 (0,891). Todos **no interior** da grade.
- O SGD com lr 3,0 **colapsou** (F1 0,61): é a execução instável (página 4). 1 semente por ponto: diferenças menores que ~0,003 não separam efeito de ruído.

Etapa 3 · as agendas (F1, 1 semente)



Com lr **constante** o Muon perde do AdamW (**0,847** contra **0,853**): a vantagem do Muon exige a queda do lr. O WSD ficou abaixo do warmup + cosseno nos dois.

Etapa 4 · confirmação (3 sementes)



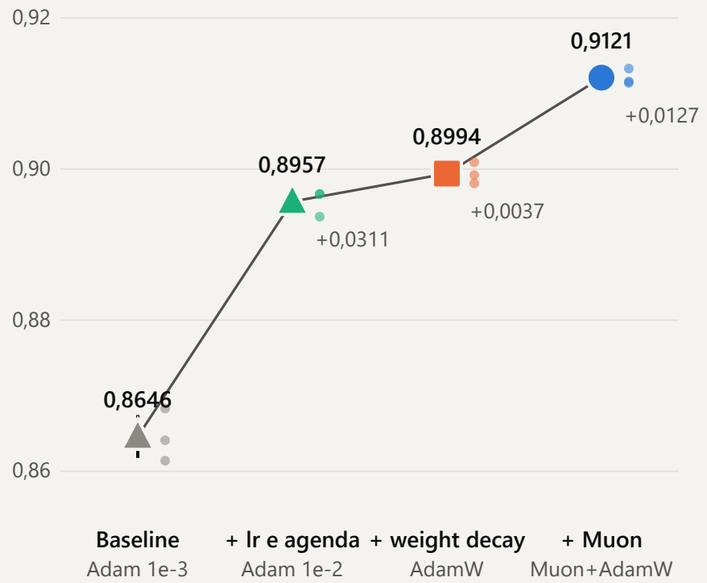
- **Vencedora:** Muon lr 0,03 + warmup/cosseno, **0,9121 ± 0,0009** contra 0,8646 ± 0,0028 da baseline: **16× o desvio**, então há vencedor.
- Cosseno puro empata (0,9111 ± 0,0006): a diferença é menor que o desvio, então o **warmup não fez diferença** aqui. O WSD fica 0,0035 abaixo.
- AdamW (0,8994) contra Adam (0,8957) no mesmo lr e agenda: o weight decay soma +0,0037.

4 · Por que funciona: o que os sinais mostram e onde o ganho para de valer

O diagnóstico lido no treino, a decomposição do ganho e as limitações, inclusive a execução que falhou

De onde vem o ganho

pontos pequenos = as 3 sementes · barra = ± desvio



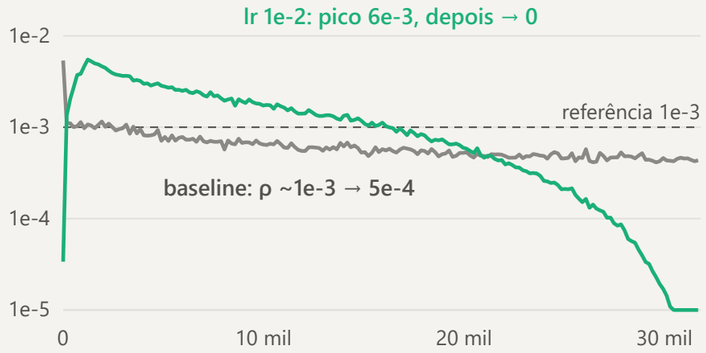
1 · lr + agenda: +0,031 (⅔ do ganho) · lr de 1e-3 para 1e-2 com queda a zero, ainda no Adam: 0,8646 → 0,8957.

2 · weight decay: +0,004 · Adam → AdamW: 0,8957 → 0,8994. Controla a norma dos pesos, mas o F1 quase não muda.

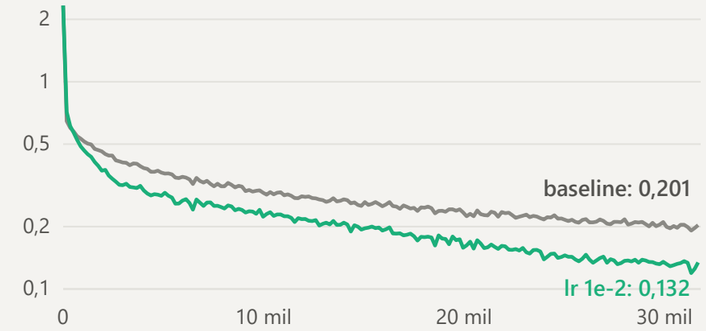
3 · Muon: +0,013 (¼ do ganho) · Muon nas 2 matrizes ocultas: 0,8994 → 0,9121. Só ¼ do ganho, e exige a agenda que decai.

Diagnóstico: lr maior + queda a zero

ρ = ||Δθ||/||θ|| (tamanho do passo, escala log)



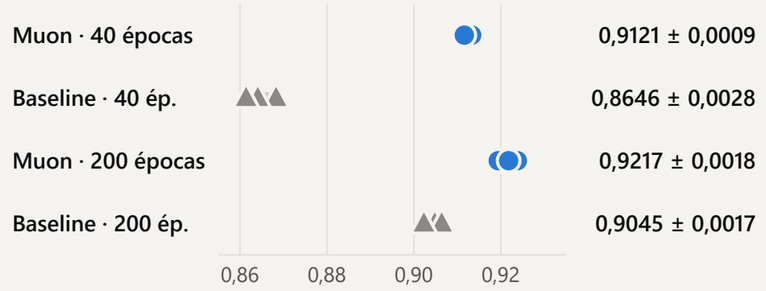
perda de treino (escala log)



- **Baseline:** ρ cai de 1e-3 a **5e-4** e a perda de treino termina em **0,201**: passo pequeno demais, a rede fica **subajustada**.
- **Adam lr 1e-2 + agenda:** ρ sobe a **6e-3** (6× a referência) e a queda do lr o leva a ~0; a perda termina em **0,132**.
- **Duas forças:** lr grande no começo para andar mais; lr perto de 0 no fim para o modelo “assentar” no vale em vez de oscilar com o ruído do mini-lote.

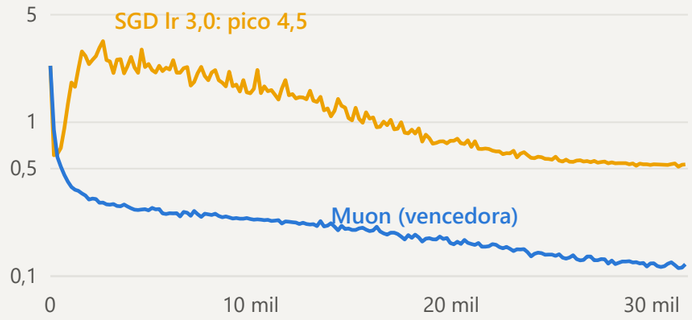
Limites do resultado

Com mais treino o ganho encolhe (1 ponto = 1 semente)



40 épocas: ganho de **+0,0475** (16× o desvio). 200 épocas (3 sementes): **+0,0172** (9× o desvio). A rede ainda não saturou em 40 épocas, então parte do ganho do Muon é **velocidade**. Mesmo assim o ganho continua maior que a variação entre sementes.

Execução instável: SGD com lr 3,0 (perda de treino)



A perda **sobe a 4,5** no passo 1.700 e ||θ|| chega a 271 (817 no fim): **passo grande demais**, e o remédio seria um lr menor. A receita vencedora desce sem picos.